

ABSTRACT

随着大语言模型智能体不断发展，人们越来越期待其能够完成需要工具调用、任务委派、信息检索以及跨会话连续性的长时程任务。然而，单纯扩展上下文窗口或增加智能体数量，并不能解决其中更根本的方法论问题：长时间运行的多智能体系统必须在有限提示预算下，联合决定应当关注什么、保留什么、压缩什么，以及如何维持行为连续性。现有研究往往将这些问题分开讨论，分别聚焦于智能体分解、长上下文建模、检索增强或记忆模块，而缺少统一视角。

本文提出“大象-海鸥框架”（Elephant-Seagull Framework），作为面向长时程多智能体大语言模型系统的一种统一方法。该框架围绕四个协同机制展开：大象注意力（Elephant Attention），即一种系统级显著性策略，用于优先保留已验证、可复用且具有社会性意义的上下文；北美海鸥记忆（North American Seagull Memory），即一种迁徙式长期记忆机制，用于决定何时让记忆脱离局部执行范围、跨运行持久化保存，并在未来重新相关时返回；长时程注意力（Long-Horizon Attention），用于通过窗口、摘要、状态快照和产物汇总维持执行连续性；以及上下文压缩（Context Compression），将提示构造形式化为在类型化上下文片段上的预算约束选择问题。

该方法进一步通过MGCM（Matriarch-Governed Collective Memory，族长治理的集体记忆）与事件中心可观测性（event-centric observability）形成闭环，把局部记忆、候选共享笔记、集体提升以及todo投影纳入统一治理流程。在这一表述中，可观测性不再是外围日志设施，而是方法本身的组成部分，因为它为记忆提升、调试和进度状态重建提供了结构化证据。

本文是一篇纯方法论文。我们并不在缺乏证据的情况下宣称已取得基准最优结果，而是提出一套严格的评估方案，用于验证长时程性能、记忆复用、预算鲁棒性与可解释性。因此，本文的贡献在于提出了一个统一的研究框架，以及一套可执行的实验设计，用于研究现实协作与上下文约束下的长时程多智能体大语言模型系统。

关键词：大语言模型智能体；多智能体系统；大象注意力；北美海鸥记忆；长时程推理；上下文压缩；MGCM；事件中心可观测性。

1. 引言

大语言模型正迅速从单轮文本生成器演化为能够规划、检索、调用工具、与外部软件协同并在长时间跨度内维持任务状态的自主系统。综述研究表明，这类系统的实际能力已不再仅仅取决于底层模型本身，还取决于其外围的智能体栈如何控制推理、记忆、环境交互与自我监控(Wang et al., 2024)。当任务超出一次提示-响应循环时，这种转变尤为明显。长篇研究、编码、分析或多阶段执行都要求系统在大量决策、工具调用、子任务交接与延迟反馈中保持稳定。在这种场景下，单智能体提示和朴素的长上下文累积会变得愈发脆弱。

其核心困难并不仅仅来自规模，而是来自耦合治理。长时程多智能体系统至少面临四类相互依赖的挑战。第一，协作会带来协调压力：系统必须决定由哪个智能体执行、应交接哪些上下文，以及专业化输出如何影响集体行为。第二，长期运行会带来记忆压力：系统必须决定哪些内容应保持短暂、哪些应提升为共享记忆，以及哪些值得跨运行持久保存。第三，有限提示预算会带来压缩压力：候选上下文几乎总是超过可用提示容量。第四，扩展执行会带来可观测性压力：如果没有结构化轨迹，便很难诊断失败、估计成本，甚至难以重建一次运行中究竟发生了什么。

现有研究确实覆盖了该问题的重要部分，但很少将其统一起来。关于基于大语言模型的自主智能体研究主要强调规划、工具使用和反馈闭环(Wang et al., 2024; Yao et al., 2023; Shinn et al., 2023)。关于基于大语言模型的多智能体系统研究则关注角色专门化、任务分解与集体行为(Jimenez-Romero et al., 2025; Wooldridge, 2009)。长上下文建模研究强调扩大可用窗口与位置鲁棒性(Li et al., 2024)。检索与记忆研究提升了系统对外部知识与历史证据的访问能力(Lewis et al., 2020)。然而，这些方向往往仍以模块化附加件形式存在。现有文献仍缺少一种统一方法，将协作显著性、长期迁徙记忆、长时程连续性以及预算约束下的上下文压缩视为同一治理框架的组成部分。

本文正是为此提出统一框架。我们引入大象注意力作为系统级策略，用于在运行过程中优先保留经过验证且具有社会性意义的上下文；引入北美海鸥记忆作为互补机制，用于让高价值记忆跨运行迁徙，并在未

ORCID(s):

来条件满足时返回复用。随后，我们将这两者置于更大的方法框架中，并加入长时程注意力以维持长轨迹上的执行连续性，以及上下文压缩以处理预算约束下的提示构造。为使闭环更加明确，我们还将这些机制与MGCM及事件中心可观测层整合，用于把执行轨迹投影为可解释的todo状态，并为记忆治理提供结构化证据。

本文的主要贡献如下。

1. 我们提出大象注意力，一种系统级显著性策略，在多智能体大语言模型执行过程中，将注意力从单纯的新近性重新分配到已验证、可复用且具有社会性意义的上下文上。
2. 我们提出北美海鸥记忆，一种迁徙式长期记忆机制，将跨运行、跨线程的记忆迁移、持久化与返回过程形式化，而不再将记忆视为简单的对话累积。
3. 我们给出一个统一的长时程方法框架，在预算感知的统一表述下，将大象注意力、北美海鸥记忆、长时程注意力与上下文压缩纳入同一体系。
4. 我们定义一个事件中心可观测性与评估框架，把MGCM、运行事件与todo投影连接起来，以支持可解释分析、调试与后续经验验证。

2. 相关工作

2.1. 大语言模型自主智能体

大语言模型自主智能体通常被建模为在推理、行动与环境反馈之间交替循环的系统，而非一次性文本生成器。综述工作强调了规划、记忆、动作模块与自我反思等组件的重要性(Wang et al., 2024)。ReAct展示了将推理轨迹与面向工具的行动显式耦合的价值(Yao et al., 2023)，而Reflexion则引入了基于执行反馈的语言式自我改进(Shinn et al., 2023)。这些工作奠定了基础，因为它们说明了系统性能依赖于结构化执行闭环。然而，它们主要聚焦于单智能体行为，并未完整说明在长时程多智能体场景下，协作显著性、跨运行记忆迁徙与预算感知可观测性应如何联合治理。

2.2. 基于大语言模型的多智能体系统

基于大语言模型的多智能体系统通过引入角色专门化、监督者-工作者分解、协商与协作探索，扩展了智能体范式。近年来的综述与应用研究表明，多智能体架构能够提升覆盖度、并行性与问题分解能力，但同时也会带来协调成本与通信噪声(Jimenez-Romero et al., 2025; Wooldridge, 2009)。不过，多数多智能体研究仍主要将协调视为路由或角色分配问题。相比之下，关于哪些上下文应在智能体之间传播、哪些经过验证的知识应变得对集体更有影响、以及执行轨迹如何同时服务于治理与可解释性的问题，关注仍然不足。

2.3. 长上下文与长时程推理

扩展上下文长度已成为重要研究方向，因为许多真实任务超出了朴素提示累积所能稳定处理的范围。围绕旋转位置编码变体等长上下文技术的研究，提升了模型在更大窗口下的表示鲁棒性(Li et al., 2024)。然而，长时程执行并不能仅仅化约为上下文长度。即使一个系统拥有较长的上下文窗口，它仍可能失败，因为它无法保持过程连续性、无法区分高价值与低价值历史，或无法随时间维持一致的压缩状态。因此，我们将长时程推理视为一个运行时治理问题，而不仅仅是模型容量问题。

2.4. 检索、记忆与上下文管理

检索增强生成表明，访问外部知识能够显著改善知识密集型任务(Lewis et al., 2020)。更广泛地说，智能体系统越来越依赖检索、情景记忆、工作空间产物与摘要机制来应对规模问题。然而，朴素累积通常会增加噪声，而简单检索也无法回答更难的问题：哪些内容应被持久化、哪些应被提升、以及哪些内容应在未来返回。我们的框架通过在同一方法流水线中联合建模运行中的显著性、治理化提升、迁徙式长期存储以及预算约束压缩，与现有方法形成区别。

2.5. 本文工作的定位

与已有研究相比，本文方法有三点关键区分。第一，它将运行内显著性治理与跨运行迁徙记忆分离，并分别形式化为大象注意力与北美海鸥记忆。第二，它将长时程连续性与上下文压缩视为在提示预算下耦合的优化问题，而不是若干启发式工具。第三，它将事件中心可观测性从工程层面的辅助监控提升为方法论基础设施，因为结构化轨迹能够支持进度投影、记忆治理与失败分析。最终结果是：我们得到的是一个面向长时程多智能体大语言模型系统的统一框架，而不是一组松散拼接的组件。

3. 问题表述

我们考虑一个长时程多智能体大语言模型系统。它接收用户请求 x ，运行于线程状态 $\mathcal{H}_t$ 中，拥有工具集合 $\mathcal{T}$ 、可检索知识底座 $\mathcal{R}$ 、可用智能体集合 $\mathcal{A}$ ，以及多个记忆存储层。在决策步 t ，系统必须构造一个可执行提示上下文 $\mathcal{C}_t$ ，并从如下动作空间中选择动作 a_t ：

$$\mathcal{U} = \mathcal{U}_{\text{reason}} \cup \mathcal{U}_{\text{tool}} \cup \mathcal{U}_{\text{retrieve}} \cup \mathcal{U}_{\text{delegate}} \cup \mathcal{U}_{\text{memory}}. \quad (1)$$

这里，动作既可以是直接推理步骤，也可以是工具调用、检索请求、任务委派或记忆治理更新。

压缩之前的候选上下文为

$$\mathcal{X}_t = \mathcal{H}_t \cup \mathcal{M}_t^{\text{local}} \cup \mathcal{M}_t^{\text{collective}} \cup \mathcal{M}_t^{\text{migratory}} \cup \mathcal{R}_t \cup \mathcal{D}_t \cup \mathcal{S}_t, \quad (2)$$

其中， $\mathcal{M}_t^{\text{local}}$ 表示局部工作记忆， $\mathcal{M}_t^{\text{collective}}$ 表示受治理的共享记忆， $\mathcal{M}_t^{\text{migratory}}$ 表示来自历史运行并在当前返回的北美海鸥长期记忆候选， $\mathcal{R}_t$ 表示检索到的证据， $\mathcal{D}_t$ 表示委派数据包与协调元数据， $\mathcal{S}_t$ 表示策略指令或结构化控制片段。

提示构造受有限token 或字符预算 B_t 约束。令每个候选片段 $z_i \in \mathcal{X}_t$ 的大小为 ℓ_i ，则提示构造器必须选择子集 $\mathcal{C}_t \subseteq \mathcal{X}_t$ ，满足

$$\sum_{z_i \in \mathcal{C}_t} \ell_i \leq B_t. \quad (3)$$

因此，上下文构造被转化为受约束的选择问题，而非追加式对话堆积问题。

多智能体执行还引入了路由策略

$$\pi_{\text{route}} : (x, \mathcal{H}_t, \mathcal{X}_t) \mapsto \{(\alpha_j, \tau_j)\}_{j=1}^{m_t}, \quad (4)$$

其中 $\alpha_j \in \mathcal{A}$ 是被选中的智能体， τ_j 是紧凑任务数据包。系统不仅要决定由谁执行，还要决定应随委派携带哪些压缩后的上下文与记忆证据。

记忆在四个层级上受到治理：

$$\mathcal{M}_t = \{\mathcal{M}_t^{\text{local}}, \mathcal{M}_t^{\text{candidate}}, \mathcal{M}_t^{\text{collective}}, \mathcal{M}_t^{\text{migratory}}\}. \quad (5)$$

其中，局部记忆服务于当前运行；候选记忆存放尚未验证的中间知识；集体记忆存放已验证的共享知识；迁徙记忆存放可在未来返回的跨运行持久记忆。

最后，执行过程会产生事件流

$$\mathcal{E} = (e_1, e_2, \dots, e_T), \quad (6)$$

其中每个事件都包含诸如run ID、thread ID、task ID、阶段与元数据等标识。这些事件并不是附属产物，而是形式化研究对象的一部分，因为它们同时支持运行时可观测性与基于事件的todo 投影。

在这一表述下，研究问题可以归结为：设计一族统一策略

$$\Pi = \{\pi_{\text{elephant}}, \pi_{\text{seagull}}, \pi_{\text{horizon}}, \pi_{\text{compress}}, \pi_{\text{mgcm}}, \pi_{\text{obs}}\} \quad (7)$$

以便在有限上下文预算与多步执行条件下，提高长时程多智能体系统的性能、连续性与可解释性。

4. 方法

4.1. 总体框架

本文提出的大象-海鸥框架是一种面向长时程多智能体大语言模型系统的统一运行时方法。其执行流程可概括为

$$x \rightarrow \text{路由} \rightarrow \text{上下文构造} \rightarrow \text{推理/委派} \rightarrow \text{工具/检索执行} \rightarrow \text{记忆提升/迁移} \rightarrow \text{可观测性投影}. \quad (8)$$

给定请求 x 后，系统首先解析路由策略，决定任务是保持单智能体执行、进入工作流，还是委派给专业化智能体。随后，系统从线程历史、记忆层、检索证据、策略指令与委派数据包中构造候选上下文。大象

注意力与上下文压缩共同决定在当前提示预算下哪些片段能够保留下来。活跃智能体或监督者随后基于压缩后的提示进行推理，在需要时调用工具或检索，也可继续拆分并委派子任务。执行结束后，MGCM 决定产生的知识是保留在本地、成为候选共享笔记，还是被提升为集体记忆。随后，北美海鸥记忆进一步决定哪些高价值记忆应迁移到跨运行持久存储中，以及未来在何种条件下返回。与此同时，所有执行阶段都会产生结构化事件，并被持久化与投影到todo 视图中，用于进度重建。

这种表述使该框架成为一种以方法为中心、而非以架构为中心的方案。重点不在于枚举软件模块，而在于明确规定上下文、记忆与协作如何跨时间被联合治理。

4.2. 大象注意力

大象注意力并不是神经网络内部的注意力层，而是一种系统级显著性策略，用于在协作执行中对候选上下文进行耐久性重要度排序。对于每个候选片段 $z_i \in \mathcal{X}_i$ ，定义其大象注意力分数为

$$s_i^{\text{EA}} = \alpha \text{Rel}(z_i, x) + \beta \text{Val}(z_i) + \gamma \text{Reuse}(z_i) + \delta \text{Out}(z_i) - \lambda \text{Red}(z_i), \quad (9)$$

其中Rel 衡量任务相关性，Val 衡量验证支持程度，Reuse 衡量跨运行或跨智能体的复用程度，Out 衡量其与成功结果的关联，Red 则用于惩罚冗余。

大象注意力的治理偏置可写为

$$\beta + \gamma + \delta > \alpha_{\text{recency}}, \quad (10)$$

这表示经过验证、可复用并受到结果支持的上下文，能够压过仅仅“最新”的上下文。这一点不同于以新近性为主导的提示组装方式，后者往往会高估新近但不稳定的交互历史。

在实践中，大象注意力要解决的是一个典型的协作问题：当多个智能体、工具输出与中间结果争夺有限提示预算时，什么应当持续保持影响力。当专业化智能体的产出与已验证规则需要在后续决策中持续发挥作用时，该机制尤为重要。

4.3. 北美海鸥记忆

北美海鸥记忆负责治理长期迁徙记忆。它与大象注意力的目标不同。大象注意力关注的是当前运行期间哪些上下文更重要；而北美海鸥记忆关注的是哪些记忆应当离开当前运行、被长期持久化，并在未来合适条件下重新返回。

对于一个记忆候选 m ，定义其迁移分数为

$$\mu(m) = \rho_1 \text{Val}(m) + \rho_2 \text{Reuse}(m) + \rho_3 \text{Out}(m) + \rho_4 \text{Gen}(m) - \rho_5 \text{Noise}(m), \quad (11)$$

其中Gen 衡量跨任务通用性，Noise 用于惩罚局部性过强或置信度不足的内容。当满足

$$\mu(m) \geq \theta_{\text{mig}} \quad (12)$$

时，记忆发生迁移。新的运行开始时，迁徙记忆不会整体回流，而是对每条存储项计算返回分数

$$r(m, x, \mathcal{H}_t) = \kappa_1 \text{Match}(m, x) + \kappa_2 \text{Thread}(m, \mathcal{H}_t) + \kappa_3 \text{Reuse}(m) - \kappa_4 \text{Stale}(m), \quad (13)$$

并仅在

$$r(m, x, \mathcal{H}_t) \geq \theta_{\text{return}} \quad (14)$$

时重新引入。

这形成了一种迁徙式记忆模型：当记忆足够可靠且具有通用性时，它会从局部执行中迁出；而只有当未来任务、线程或执行状态再次显示其有用时，它才会迁回。核心观点是：持久记忆应更像选择性迁徙，而不是被动堆积。

4.4. 长时程注意力

长时程注意力用于在长轨迹执行过程中维持连续性。它不同于长期记忆。长期记忆决定什么内容能跨运行保存；长时程注意力决定的是当前运行内部如何在不重放全部历史的前提下跨越大量步骤保持状态。

在步骤 t ，系统维护的长时程状态为

$$\mathcal{L}_t = \mathcal{W}_t \cup \Sigma_t \cup \mathcal{P}_t \cup \mathcal{A}_t, \quad (15)$$

其中 $\mathcal{W}_t$ 是近期窗口， Σ_t 是较早交互的紧凑摘要， $\mathcal{P}_t$ 是过程状态的结构化快照， $\mathcal{A}_t$ 是用于记录笔记、计划或阶段性产物的产物汇总层。

摘要与快照会周期性刷新：

$$\Sigma_{t+1} = \begin{cases} g(\mathcal{H}_{0:t}) & \text{若 } t \bmod k_\Sigma = 0, \\ \Sigma_t & \text{否则,} \end{cases} \quad (16)$$

$$\mathcal{P}_{t+1} = \begin{cases} \phi(\text{state}_t) & \text{若 } t \bmod k_P = 0, \\ \mathcal{P}_t & \text{否则。} \end{cases} \quad (17)$$

当发生重要工具调用或检索里程碑时，产物汇总也会按每隔 k_A 步的方式更新。

长时程注意力的作用在于保持轨迹级一致性。它持续维护系统正在做什么、已经做了什么、哪些产物重要、当前执行处于哪个阶段，即便原始对话记录已经大到无法完整保留。

4.5. 上下文压缩

上下文压缩将异质候选上下文转化为预算约束下的优化问题。设每个片段 z_i 都具有类型 t_i 、大小 ℓ_i 、大象注意力分数 s_i^{EA} ，以及由当前执行阶段 σ_t 决定的阶段感知权重 $\omega(t_i, \sigma_t)$ 。定义片段的有效效用为

$$u_i = \omega(t_i, \sigma_t) \cdot s_i^{\text{EA}} - \xi \text{Red}(z_i), \quad (18)$$

其中 $\text{Red}(z_i)$ 表示冗余抑制项。

于是，提示构造可写为

$$\max_b \sum_{i=1}^n b_i u_i \quad (19)$$

$$\text{s.t.} \quad \sum_{i=1}^n b_i \ell_i \leq B_t, \quad (20)$$

$$b_i \in \{0, 1\}. \quad (21)$$

这里的选择操作对象是类型化上下文片段，而不是原始文本块。片段类型可以包括对话历史、记忆胶囊、检索证据、委派数据包、任务指令、摘要与工作产物。阶段感知加权使系统能够在不同执行阶段偏好不同片段类型，例如在路由阶段提高委派数据包的权重，而在工具返回后的推理阶段提高工具观测的权重。

因此，上下文压缩与简单截断有三点差异。第一，它基于类型化片段，而非仅依据位置启发式。第二，它采用阶段感知加权，而非固定的统一规则。第三，它显式抑制冗余，避免重复证据在同一预算下挤占更高价值的上下文。

4.6. 记忆治理与事件中心进度投影

该框架最终通过将记忆治理与事件中心可观测性耦合起来形成闭环。**MGCM**将记忆组织为局部记忆、候选共享笔记、集体记忆与迁徙式长期记忆。对于一个候选记忆项 m ，定义其提升分数为

$$p(m) = \eta_1 \text{Rel}(m) + \eta_2 \text{Evi}(m) + \eta_3 \text{Reuse}(m) + \eta_4 \text{Out}(m) + \eta_5 \text{Coll}(m), \quad (22)$$

其中 Evi 表示证据支撑， Coll 表示集体强化。当满足

$$p(m) \geq \theta_{\text{promote}} \quad (23)$$

时，该记忆会被提升到受治理的集体记忆中；而若要进一步提升为迁徙式长期记忆，还需满足

$$\lambda_1 p(m) + \lambda_2 \mu(m) \geq \theta_{\text{long}}. \quad (24)$$

执行过程同时会产生事件流

$$\mathcal{E} = (e_1, e_2, \dots, e_T), \quad (25)$$

其中包括运行开始、任务创建、推理阶段、工具调用、检索完成、任务委派、人工反馈与运行完成等事件。我们定义todo 投影算子

$$\Psi: \mathcal{E} \rightarrow \mathcal{Q}, \quad (26)$$

其中 $\mathcal{Q}$ 为运行级进度状态。每个todo 项 $q_k \in \mathcal{Q}$ 按如下方式递增更新:

$$q_k^{(t+1)} = \Psi(q_k^{(t)}, e_{t+1}). \quad (27)$$

这种事件中心视角有两个方法论作用。第一，它为记忆治理提供结构化证据，因为提升决策可以依赖已验证轨迹、复用统计与结果信息。第二，它为长时程运行提供可解释的进度重建能力。从这个意义上说，事件中心可观测性是推理-记忆闭环的一部分，而不是外置日志工具。

5. 实验设计

5.1. 研究问题与benchmark 选择

本文围绕五个研究问题组织实验，但主文证据被明确分成两层。第一层是公开benchmark 主证据，用于支撑关于整体性能、记忆复用与预算鲁棒性的主要论断；第二层是补充性诊断证据，用于解释连续性、可观测性与机制失效模式，而不再与公开benchmark 处于同一证据等级。这一分层不是叙事上的重新包装，而是由当前真实数据的覆盖强度决定的。RQ1 的公开benchmark 证据相对最完整；本轮补跑后，RQ2-RQ4 已不再停留在单个seed，但其覆盖仍然不均匀，尚未达到跨模型、跨seed、跨benchmark 同步完整的正式标准；RQ5 目前仍只有自定义诊断环境，因此不同研究问题能够承载的结论强度并不相同。

研究问题与基准的映射如下。RQ1 使用GAIA、HotpotQA 与MuSiQue，检验统一框架在长时程协调、多跳推理与工具辅助任务上的整体表现；RQ2 使用当前仓库内置的HotpotQA 与MuSiQue 高干扰切片，检验大象注意力是否能够在竞争性上下文中改善证据保留；RQ3 使用LoCoMo 与LongMemEval，检验迁徙式长期记忆是否在提高recall 与reuse 的同时控制stale memory；RQ4 使用LongBench 与InfiniteBench 的当前bundled slice 研究预算收缩时的退化曲线；RQ5 使用AgentOrch Failure Suite 作为补充性的可观测性诊断环境。本文所有主表、主图和样本覆盖信息均直接追溯到experiments/results_formal 中的真实运行记录，而不是手工填表或示例性数字。

5.2. 运行协议、基线与统计口径

运行协议在正式实验中尽量固定。主文只纳入真实模型，参考模型为gpt-4o，低成本真实模型集合为gpt-4o-mini、deepseek-chat 和qwen-plus。主预算档位为12000 tokens，RQ4 额外扫描更低预算档位，用于观察退化曲线而非单点得分。主指标直接采用正式运行文件中的quality_score，成功率、token 使用量以及任务特定元数据也全部来自真实结果目录。若运行失败、超时或低分，均按原始记录纳入汇总，不做事后修正。

基线设置按研究问题固定，以避免收益来源混杂。RQ1 比较完整框架、单智能体基础版与去除大象注意力的多智能体版本；RQ2 比较完整框架、去除大象注意力的多智能体版本与单智能体长上下文版本；RQ3 比较完整框架、朴素长期记忆版本与去除海鸥记忆的多智能体版本；RQ4 比较完整框架、去除上下文压缩的版本与去除长时程注意力的版本；RQ5 仅作为补充分析，比对完整框架与普通日志版本。这样的设计是为了把“更多智能体”“更长上下文”和“显式治理机制”这三类可能的收益来源分开讨论，而不是只给出一个难以解释的混合总分。

统计汇总默认以run-level 记录为单位，并在表中同时报告样本数、seed 数、模型数与运行数，避免把极小样本下的1.00 或0.00 误读为大规模稳定现象。主结果表给出均值与bootstrap 95% 置信区间；针对full_framework 与关键基线的比较，另行报告配对差值、bootstrap 区间与sign test 的近似 p 值。低成本模型聚合结果只用于检验方向是否跨模型保持，不用于主张绝对性能上界。由于当前仓库内置的是benchmark 对齐切片，而非完整公开测试集，正文统一把这些结果表述为“当前仓库切片上的真实结果”，而不把它们写成完整公开benchmark 排行结论。

图1 展示了主文最重要的公开benchmark 结果。图中直接比较的是各研究问题上full_framework 与关键基线之间的主指标差距。从读图上看，RQ1 和RQ4 的差距最为明确；RQ2 在本轮补跑后仍保留正向配对gap，但优势已经明显弱于RQ1 与RQ4；RQ3 则在当前真实数据上依然没有形成正向优势。由此可见，当前证据支持统一框架在长时程任务和预算鲁棒性上表现更好，而RQ2 更适合被描述为“存在弱正向趋势但证据尚不闭合”，这并不意味着所有模块贡献都被同等强度地验证。

Table 1

Public-benchmark coverage used in the main paper. All counts refer to the currently collected benchmark-aligned local slices bundled in this repository.

Experiment	Benchmark	Split	Samples	Models	Seeds	Runs
RQ1 Long-Horizon Tasks	GAIA	official_subset	2	4	3	28
RQ1 Long-Horizon Tasks	HotpotQA	official_subset	2	4	3	28
RQ1 Long-Horizon Tasks	MuSiQue	official_subset	2	4	3	28
RQ2 Elephant Attention	HotpotQA	distractor_subset	2	3	5	55
RQ2 Elephant Attention	MuSiQue	distractor_subset	2	2	4	42
RQ3 Seagull Memory	LoCoMo	official_subset	2	3	5	60
RQ3 Seagull Memory	LongMemEval	official_subset	4	3	5	102
RQ4 Budget Robustness	InfiniteBench	official_subset	2	2	4	42
RQ4 Budget Robustness	LongBench	official_subset	2	3	5	60

Table 2

Reference-model results on public benchmarks where available. Values are run-level means with bootstrap 95% confidence intervals on the current bundled benchmark-aligned slices.

Experiment	Variant	Primary metric	Success	Samples	Seeds	Runs
RQ1 Long-Horizon Tasks	Full Framework	0.65 [0.64, 0.67]	1.00	6	3	18
RQ1 Long-Horizon Tasks	Single Agent Basic	0.45 [0.42, 0.47]	0.00	6	1	6
RQ1 Long-Horizon Tasks	Multi-Agent No Elephant	0.61 [0.60, 0.63]	1.00	6	1	6
RQ2 Elephant Attention	Full Framework	0.97 [0.92, 1.00]	1.00	4	5	18
RQ2 Elephant Attention	Multi-Agent No Elephant	0.97 [0.92, 1.00]	1.00	4	5	18
RQ2 Elephant Attention	Single Agent Long Context	1.00 [1.00, 1.00]	1.00	4	4	16
RQ3 Seagull Memory	Full Framework	0.93 [0.86, 0.98]	1.00	6	5	28
RQ3 Seagull Memory	Multi-Agent Naive Memory	0.96 [0.91, 1.00]	1.00	6	5	28
RQ3 Seagull Memory	Multi-Agent No Seagull	0.89 [0.80, 0.96]	1.00	6	5	28
RQ4 Budget Robustness	Full Framework	0.84 [0.76, 0.88]	0.94	4	5	18
RQ4 Budget Robustness	Multi-Agent No Compression	0.65 [0.59, 0.69]	0.89	4	5	18
RQ4 Budget Robustness	Multi-Agent No Long Horizon	0.73 [0.64, 0.78]	0.89	4	5	18
RQ5 Observability	Full Framework	1.00 [1.00, 1.00]	1.00	2	1	2
RQ5 Observability	Multi-Agent Plain Logs	1.00 [1.00, 1.00]	1.00	2	1	2

图 1 同时也揭示了证据边界。RQ1 已覆盖三个公开benchmark、四个真实模型和三个随机种子，因此仍是当前最接近正式主证据标准的实验簇；RQ2、RQ3 和RQ4 虽然通过本轮补跑获得了更多真实seed，但其benchmark 与模型覆盖依然不均匀。例如，RQ2 现在已不再是单模型切片，但MuSiQue 仍只覆盖两个真实模型，RQ4 的InfiniteBench 也仍只有两个真实模型。因此，我们可以把RQ1 写成“当前证据下表现更好”，把RQ4 写成“当前仓库切片上显示出更稳健的退化曲线”，把RQ2 写成“存在有利于框架的弱正向迹象”，但仍不能把RQ2 和RQ3 写成稳定成立的泛化结论。

图 2 展示的是低成本真实模型聚合结果。它说明，在当前已收集的公开benchmark 仓库切片上，RQ1 与RQ4 的收益方向并不只出现在参考模型gpt-4o 上，而是在低成本模型集合中也保持为正。RQ2 的低成本模型聚合结果依旧偏向full_framework，说明大象注意力在高干扰上下文中的作用并非完全不可见，但这种趋势目前仍建立在有限模型覆盖之上。

但该图同样包含负面或不充分发现。RQ2 虽然出现了正向均值差距，但sign test 的结果仍未达到足够稳健的统计支持，跨模型一致性也只在少数模型上成立，而且低成本单智能体长上下文基线目前仍只有一个真实模型；RQ3 则依旧没有出现预期中的正向间隔，在跨模型一致性表中也只呈现混合方向。因此，图 2 只能支持“部分模块收益具有一定跨模型迁移性”，不能支持“所有模块在不同模型上都一致成立”。

图 3 对应RQ3。该图展示了记忆reuse、长期recall 与stale memory 注入三个方向的诊断指标。当前真实结果的关键发现不是“海鸥记忆已经显著更强”，而是相反：full_framework 在recall 与reuse 上并未明显拉开与退化变体的距离，stale memory 指标也没有形成足够清晰的优势。因此，当前collected slice 只能说明迁徙式记忆值得继续检验，而不能据此声称它已经稳定实现了“提高recall 且不增加stale memory”的目标。

Table 3

Cheap real-model aggregate on public benchmarks. This table tests directional portability on the current bundled slices rather than absolute performance.

Experiment	Variant	Primary metric	Success	Models	Seeds	Runs
RQ1 Long-Horizon Tasks	Full Framework	0.44 [0.29, 0.58]	0.67	3	1	18
RQ1 Long-Horizon Tasks	Single Agent Basic	0.27 [0.18, 0.36]	0.00	3	1	18
RQ1 Long-Horizon Tasks	Multi-Agent No Elephant	0.38 [0.25, 0.50]	0.44	3	1	18
RQ2 Elephant Attention	Full Framework	0.85 [0.68, 1.00]	1.00	2	5	17
RQ2 Elephant Attention	Multi-Agent No Elephant	0.56 [0.34, 0.78]	1.00	2	4	16
RQ2 Elephant Attention	Single Agent Long Context	0.75 [0.50, 1.00]	1.00	1	3	12
RQ3 Seagull Memory	Full Framework	0.94 [0.87, 1.00]	1.00	2	4	26
RQ3 Seagull Memory	Multi-Agent Naive Memory	0.96 [0.90, 1.00]	1.00	2	4	26
RQ3 Seagull Memory	Multi-Agent No Seagull	0.98 [0.94, 1.00]	1.00	2	4	26
RQ4 Budget Robustness	Full Framework	0.77 [0.67, 0.86]	0.88	2	4	16
RQ4 Budget Robustness	Multi-Agent No Compression	0.60 [0.52, 0.67]	0.75	2	4	16
RQ4 Budget Robustness	Multi-Agent No Long Horizon	0.66 [0.55, 0.75]	0.75	2	4	16

Table 4

Paired public-benchmark comparison between the full framework and the key baseline for each research question.

Experiment	Baseline	Paired gap	Bootstrap 95		
RQ1 Long-Horizon Tasks	Single Agent Basic	0.18	[0.14, 0.21]	0.000	24
RQ2 Elephant Attention	Multi-Agent No Elephant	0.13	[0.01, 0.26]	0.180	34
RQ3 Seagull Memory	Multi-Agent No Seagull	0.00	[-0.05, 0.04]	1.000	54
RQ4 Budget Robustness	Multi-Agent No Long Horizon	0.11	[0.10, 0.12]	0.000	34

Table 5

Cross-model consistency of the full framework relative to the key baseline on public benchmarks.

Experiment	Baseline	Consistency	Avg. gap
RQ1 Long-Horizon Tasks	Single Agent Basic	3/4	0.18
RQ2 Elephant Attention	Multi-Agent No Elephant	1/3	0.11
RQ3 Seagull Memory	Multi-Agent No Seagull	1/3	-0.00
RQ4 Budget Robustness	Multi-Agent No Long Horizon	3/3	0.12

Table 6

Supplementary benchmark coverage. These diagnostic suites support mechanism analysis but do not carry the main benchmark claims.

Benchmark	Samples	Models	Seeds	Runs
AgentOrch MultiTurn Suite	2	4	1	24
AgentOrch Failure Suite	2	3	1	12

图 4 对应RQ4。图中最重要的信息不是某一个预算点的绝对高低，而是预算继续收缩时各方法的退化速度。从当前真实结果看，`full_framework` 相对于`multi_agent_no_long_horizon`和`multi_agent_no_compression` 维持了更高的主指标，配对差值也稳定为正。这支持了这样一种更谨慎的解释：在当前LongBench 与InfiniteBench 的仓库切片上，长时程注意力与上下文压缩的组合能够减缓预算压力下的性能坍塌。

不过，这一结论仍然需要受限表述。当前公开结果主要来自LongBench 的官方子集切片，样本量和seed 数都偏小，因此它更接近“当前切片上显示出较平缓退化曲线”，而不是“已在完整长上下文benchmark 上稳定证明”的结论。文中所有关于预算鲁棒性的说法都应理解为这一边界下的判断。

Table 7

Supplementary diagnostic and multi-turn results for the reference model.

Benchmark	Variant	Primary metric	Samples	Seeds	Runs
AgentOrch Failure Suite	Full Framework	1.00 [1.00, 1.00]	2	1	2
AgentOrch Failure Suite	Multi-Agent Plain Logs	1.00 [1.00, 1.00]	2	1	2
AgentOrch MultiTurn Suite	Full Framework	0.73 [0.73, 0.73]	2	1	2
AgentOrch MultiTurn Suite	Multi-Agent No Elephant	0.56 [0.56, 0.56]	2	1	2
AgentOrch MultiTurn Suite	Single Agent Basic	0.33 [0.33, 0.33]	2	1	2


**Figure 1:** 公开benchmark 主结果。图中比较的是当前仓库对齐切片上的full_framework 与关键基线，而非完整benchmark 排行结论。

图 5 是扩展性补充图，而不是主结论图。它提示我们，更多agent 并不会自动转化为更高分数；一旦协作规模扩大，协调质量、上下文传递与记忆治理就会成为新的瓶颈。因此，这张图的价值在于说明“协作规模需要治理”，而不在于证明“增加agent 数量本身就是优势来源”。

5.3. 跨模型结果

跨模型分析的意义在于回答一个更窄但非常关键的问题：当前观察到的收益是否依赖某一个特别强的模型。从现有真实数据看，可以支持的说是“部分结论具有一定方向稳定性”，尤其体现在RQ1 与RQ4；RQ2 在补跑后仍保留弱正向趋势，但这种趋势既没有在参考模型上清晰拉开，也没有形成充分的跨模型一致性；RQ3 则依旧只呈现混合方向，而不能支持稳定收益。也就是说，框架表现出的并不是完全统一的泛化图景，而是若干模块已经出现了可迁移的正向信号，另一些模块则仍需更大规模补跑验证，甚至可能需要重新审视模块本身的设计假设。

5.4. 诊断与定性分析

正式基准层之外，本文还保留了一条补充性诊断轨道。每次正式运行都会记录运行事件、todo 投影、记忆治理信号、上下文选择轨迹与逐样本执行元数据，因此框架的评估不再只关心一个变体是否成功，也关心其成功或失败是否可被结构化解释。这里需要再次强调的是：这类结果承担的是机制说明作用，而不是公开benchmark 级主结论。

图 6 展示了RQ5 的补充诊断结果。这里最重要的不是Failure Suite 上的总体quality_score，因为该指标在当前小样本切片上接近饱和；真正有解释力的是轨迹覆盖率、todo 一致性和诊断准确率等可观测性指标。结果说明，事件中心可观测性有助于形成更可重建的任务轨迹，从而提高故障定位能力，但这类结果目前只应被看作机制性补充证据，而不能替代公开benchmark。




Figure 2: 低成本真实模型聚合结果。该图用于检验收益方向是否跨模型保持，而不是证明低成本模型的绝对上限。




Figure 3: RQ3 记忆诊断图。关键观察是recall、reuse 与stale memory 是否同时改善，而不是单一指标的局部升高。

5.5. 多智能体多轮对话分析

多智能体多轮对话是一个有解释力但证据等级较低的压力测试，因为它同时要求系统保留早期约束、维持委派连续性，并在后续轮次中吸收新需求而不丢失已有结构。这恰好对应大象注意力、海鸥记忆、长时程注意力与上下文压缩需要协同工作的场景。

图 7 展示了多轮对话补充结果。它表明，在AgentOrch MultiTurn Suite 这一专门构造的连续性环境中，完整框架比去除大象注意力或退化为单智能体更容易保持跨轮约束与委派连续性。这一现象与RQ1 中观察到的长时程协作收益在方向上相容，但由于该套件不是公开benchmark，且当前覆盖仍小，因此本文只把它作为辅助解释材料。

6. 结果讨论

综合以上结果，当前真实数据能够支持三类较为稳健的判断。第一，统一框架在公开benchmark 的长时程任务上优于单智能体强退化基线，尤其体现在RQ1。第二，在当前仓库对齐切片上，长时程注意力与上




Figure 4: RQ4 预算鲁棒性曲线。主文关注的是预算收缩时的退化趋势，而不是某个预算点的单次高低。




Figure 5: 补充性的扩展性结果。更多agent 并不自动带来更强性能，因此该图只作为机制补充证据。

下文压缩组合显示出更清晰的正向预算鲁棒性信号。第三，大象注意力在高干扰上下文中的收益只呈现弱正向趋势，现阶段更适合被描述为“证据未闭合但方向略偏正”而非稳定结论。事件中心可观测性与多轮连续性结果则继续作为机制补充，帮助解释为什么该框架更适合长时程协作任务。

与此同时，本文也必须保留几类明确的负面或不充分发现。**RQ2** 虽然出现了正向gap，但统计显著性和跨模型一致性仍不足，而且参考模型结果并未与低成本聚合结果一起形成清晰分离，因此不能把它写成稳定成立的模块收益；**RQ3** 当前依然没有形成海鸥记忆优于退化变体的稳定证据，甚至在部分比较中与朴素记忆版本接近或更弱；部分图表中的高成功率对应的实际样本量仍然偏小，因此不能被表述为大规模稳定现象。换句话说，当前稿件更接近一篇“公开benchmark 主导、真实数据驱动、但结论边界严格受控”的方法论文，而不是已经完成全面优越性证明的成熟benchmark 论文。




Figure 6: 补充性的RQ5 诊断结果。可观测性图用于解释轨迹覆盖与故障定位能力，不承担公开benchmark 级主结论。




Figure 7: 补充性的多轮对话结果。该图用于说明跨轮连续性与委派保持，而非主文核心benchmark 结论。

7. 局限性

当前稿件有意对尚未完成的部分保持诚实。若干重要限制仍然存在：

- 当前主文中的若干benchmark 仍是仓库内置的对齐切片，而非完整公开benchmark。
- 真实模型调用成本与运行时间仍限制benchmark 覆盖范围；尽管本轮已把RQ2-RQ4 的参考模型核心对照补到五个seed，模型与benchmark 覆盖仍不均匀。
- 主要任务质量指标依赖judge-based 评分，这可能引入评价偏差；人工评审与双盲复核仍需补充。

- 自定义诊断套件只能作为补充证据，不能替代公开**benchmark** 去支撑主结论。
- 当前跨模型分析仍局限于少量真实模型，尚不足以支撑更强的跨提供商泛化陈述。
- 成本-性能权衡、失败类型附录以及更大规模多**seed** 复现实验仍未扩展到投稿级完整度。

这些局限之所以重要，是因为方法论文的说服力并不来自概念新颖本身，而来自“概念、实验协议、统计汇总与结论边界”四者之间是否严格一致。因此，当前版本更适合被理解为一个已经具备真实**benchmark** 主证据的高强度稿件雏形，而不是已经完成全部验证的最终优越性证明。

此外，该方法本身也存在风险。若系数校准不当，大象注意力可能会过度偏向历史上已验证的信息，从而抑制真正有价值的新证据。若迁移与返回阈值设置过于宽松，北美海鸥记忆仍可能积累陈旧记忆。长时程注意力依赖摘要与状态快照算子的质量，而这些算子本身也可能引入失真。若冗余抑制调节不佳，上下文压缩可能会丢弃那些低频但决定性的证据。最后，事件中心可观测性虽然提升了可解释性，但也引入了额外的存储与实现开销，未来需要显式测量。

8. 结论

本文将长时程多智能体大语言模型系统重新表述为一个统一的治理问题，而不是若干工程模块的临时拼装。所提出的大象-海鸥框架把大象注意力、北美海鸥记忆、长时程注意力、上下文压缩、**MGCM** 与事件中心可观测性组织为一组可联合分析的机制，用于共同治理上下文、记忆、协作与进度重建。

基于当前真实结果，本文能够得出的结论是审慎而明确的：统一框架在公开**benchmark** 的长时程任务上相对单智能体强退化基线表现更好，并在预算鲁棒性上显示出较清晰的正向信号；与此同时，大象注意力在高干扰上下文中的收益目前只表现为弱正向趋势，尚未达到稳定结论的强度，海鸥记忆的独立贡献则在当前**bundled slice** 上未见稳定优势，仍需更大规模、更多**seed** 与更完整**benchmark** 覆盖来进一步验证。补充性的诊断与多轮结果为机制解释提供了支持，但不应被误读为主**benchmark** 级证据。

因此，本文的主要价值在于给出了一套已经被真实数据部分支持、且能继续扩展的统一实验与方法框架。下一步工作应集中于补齐公开**benchmark** 覆盖、完成五**seed** 正式协议、增加人工评审与更强统计检验，并在不改变核心方法表述的前提下，把当前稿件推进到更接近正式投稿的证据强度。

References

- Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., Chen, Z., Tang, J., Chen, X., Lin, Y., Zhao, W.X., Wei, Z., Wen, J., 2024. A survey on large language model based autonomous agents. *Frontiers of Computer Science* 18, 186345. <https://doi.org/10.1007/s11704-024-40231-1>.
- Jimenez-Romero, C., Yegenoglu, A., Blum, C., 2025. Multi-agent systems powered by large language models: applications in swarm intelligence. *Frontiers in Artificial Intelligence* 8, 1593017. <https://doi.org/10.3389/frai.2025.1593017>.
- Li, R., Xu, J., Cao, Z., Zheng, H.-T., Kim, H.-G., 2024. Extending context window in large language models with segmented base adjustment for rotary position embeddings. *Applied Sciences* 14, 3076. <https://doi.org/10.3390/app14073076>.
- Wooldridge, M., 2009. *An Introduction to MultiAgent Systems*. Wiley, Chichester.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Kuttler, H., Lewis, M., Yih, W.-t., Rocktaschel, T., Riedel, S., Kiela, D., 2020. Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems* 33, 9459–9474.
- Yao, S., Zhao, J., Yu, D., Du, N., Shafraan, I., Narasimhan, K., Cao, Y., 2023. ReAct: Synergizing reasoning and acting in language models. In: *International Conference on Learning Representations*.
- Shinn, N., Cassano, F., Labash, B., Gopinath, A., Narasimhan, K., Yao, S., 2023. Reflexion: Language agents with verbal reinforcement learning. *Advances in Neural Information Processing Systems* 36.